

Inteligência Artificial na previsão de resultados do UFC e na otimização das estratégias dos lutadores

Sheng Yan,
Politécnico de Wuhan,
China
373335118@qq.com

Linjun Liu Lincoln University
College, Malásia
1241961866@qq.com

Comite Ubaldo*
Universidade da Calábria,
Itália ubaldo.comite@unical.it

1 Introdução

Resumo

A IA tem sido cada vez mais amplamente aplicada na indústria do esporte, desde a previsão de resultados de lutas até a tomada de decisões táticas, desde ajudar o árbitro a tomar decisões mais precisas até auxiliar o atleta a prevenir possíveis lesões. Este estudo se concentra em como utilizar o aprendizado de máquina para prever o resultado das lutas e identificar os fatores que influenciam o resultado no UFC, um dos esportes mais lucrativos. O conjunto de dados utilizado no estudo abrange todas as lutas de março de 1994 a março de 2021, com mais de 100 variáveis de informação sobre os dois lutadores no ringue, adequadas para serem processadas por métodos de aprendizado de máquina. Random Forest, Gradient Boosting Decision Tree (GBDT) e Support Vector Machines (SVM) foram adotados para prever o resultado das lutas e identificar as 10 características mais importantes. Métricas de desempenho como precisão, kappa de Cohen, sensibilidade e especificidade foram utilizadas para comparação. Random Forest e GBDT alcançaram melhorias utilizando apenas características importantes, enquanto o SVM apresentou queda tanto na precisão quanto na confiabilidade. Embora os resultados das 10 características mais importantes tenham variado entre os modelos, a data em que a luta ocorreu e a diferença de idade entre os dois lutadores estão entre as duas primeiras em todos os três modelos.

Conceitos de CCS

• **Metodologias de computação** → Inteligência artificial; Metodologias de pesquisa.

Palavras-chave

IA, Inteligência Artificial, UFC, Previsão, Estratégias, Random Forest, GBDT, SVM

Formato de referência ACM:

Sheng Yan, Linjun Liu e Comite Ubaldo. 2024. Inteligência Artificial na Previsão de Resultados do UFC e Otimização de Estratégias de Lutadores. Em *2024 9ª Conferência Internacional sobre Processamento Inteligente de Informação (ICIIP 2024)*, 21 e 22 de novembro de 2024, Bucareste, Romênia. ACM, Nova York, NY, EUA, 5 páginas. <https://doi.org/10.1145/3696952.3696966>

*Autor correspondente.



Este trabalho está licenciado sob uma Licença Creative Commons Atribuição Internacional 4.0.

ICIIP 2024, 21 e 22 de novembro de 2024, Bucareste, Romênia

© 2024 Direitos autorais reservados pelo(s)
proprietário(s)/autor(es). ACM ISBN 979-8-4007-1807-6/24/11
<https://doi.org/10.1145/3696952.3696966>

1.1 Contexto da pesquisa

Na década de 1950, quando o cientista da computação Alan Turing projetou o primeiro algoritmo de xadrez, a aplicação da tecnologia de IA nos esportes deu seus primeiros passos, mesmo que, na época, fosse apenas uma simulação no papel. Um avanço verdadeiro e significativo surpreendeu o mundo inteiro em 1997, quando o supercomputador Deep Blue, da IBM, derrotou o então campeão mundial de xadrez, Garry Kasparov. O mundo testemunhou as poderosas capacidades da IA em jogos estratégicos, e os especialistas na área do esporte perceberam o grande potencial da aplicação da IA, que não se limita apenas aos jogos estratégicos.

A aplicação da IA, incluindo processamento e análise de dados, reconhecimento de padrões, suporte automático à tomada de decisões e capacidades de aprendizagem adaptativa sistemática, tem sido implementada em muitas áreas dos esportes modernos. O sistema Hawk-Eye, de grande sucesso, tem sido aplicado em muitos esportes, como futebol, tênis, badminton e críquete, entre outros. A IA foi incorporada ao sistema, trabalhando com várias câmeras de alta velocidade e utilizando triangulação para calcular a posição da bola com precisão, a fim de ajudar os árbitros a tomar decisões corretas.

A IA tem sido amplamente aplicada na previsão de resultados de partidas, na análise do desempenho dos jogadores, na formulação de táticas e na otimização de planos de treinamento, com o auxílio do aprendizado de máquina. Com as modernas tecnologias de captura de imagens e análise de vídeo, cada movimento do jogador pode ser registrado sistematicamente e convertido em dados, que podem ser interpretados pelos pesquisadores em diferentes dimensões para avaliar os níveis técnicos dos jogadores e identificar seus padrões de ataque e defesa por meio do aprendizado profundo. Fora do campo, a IA é usada para analisar dados fisiológicos e registros de treinamento dos atletas. Um programa de treinamento mais preciso e personalizado pode ser alcançado com a ajuda da IA, otimizando a intensidade e o conteúdo do treinamento e aprimorando o nível competitivo dos atletas. Além disso, a IA tem sido usada para prever riscos de lesões dos atletas e fornecer orientações preventivas correspondentes para evitar lesões potenciais, o que é vital para a carreira dos jogadores.

Como um dos eventos de artes marciais mistas (MMA) mais conhecidos do mundo, o Ultimate Fighting Championship (UFC) atraiu milhões de espectadores e inúmeros lutadores de ponta, constituindo também um gigantesco negócio esportivo global. Existem muitos fatores influentes que afetam o resultado do UFC, incluindo não apenas as habilidades e capacidades físicas dos lutadores, mas também suas estratégias, estados psicológicos e os estilos de seus adversários. A MMA-AI, uma empresa impulsionada por IA, oferece previsões gratuitas de IA para o UFC, que alcançaram precisão de cerca de 69%, superando a precisão das cotações de apostas, que acertam 66% das vezes [1]. (<https://www.mma-ai.net>) Combinando dados em tempo real e algoritmos de aprendizado de máquina, o avançado sistema de IA forma uma estratégia adaptativa com base nos

pontos fortes e fracos do adversário para ajudar o lutador e o treinador a otimizar suas estratégias rapidamente.

1.2 Questões de pesquisa e objetivos

Este estudo tem como objetivo explorar como a tecnologia de IA pode prever os resultados das lutas do UFC e fornecer orientações científicas para a otimização de estratégias destinadas a lutadores e treinadores. As questões específicas da pesquisa são: 1) Como construir modelos de previsão eficazes para os resultados das lutas, utilizando dados históricos de resultados e estatísticas técnicas dos lutadores; 2) Identificar os principais fatores que influenciam significativamente os resultados das lutas; 3) Como otimizar as estratégias dos lutadores com base no modelo de previsão e nos fatores-chave.

Esperamos fornecer novos métodos para analisar e prever lutas do UFC, bem como otimizar a estratégia. Além disso, também esperamos oferecer referências e insights para pesquisas futuras sobre a aplicação da IA no esporte.

2 Revisão da literatura

Em 1995, Lapham e Bartlett [1] destacaram os sucessos das redes neurais artificiais em experimentos e seus potenciais benefícios.

De acordo com o último relatório, em 2022, o tamanho estimado da indústria global do esporte atingiu 1,6 trilhão de dólares, e havia mais de 1 bilhão de espectadores [2], incluindo aqueles que assistem aos jogos para torcer por seus times ou jogadores favoritos, aqueles que apostam online ou offline nos resultados de diversos esportes e partidas, e aqueles que assistem aos jogos pela televisão ou em dispositivos eletrônicos. A maior preocupação de todas as partes interessadas, sejam os jogadores, a comissão técnica, os proprietários do time ou o público, é o resultado das partidas. Para os times ou jogadores, a previsão do resultado das partidas pode impactar suas decisões táticas, o recrutamento geral e a estratégia de jogo durante uma temporada [3]. Para o público e as empresas de apostas, a previsão do resultado das partidas é fundamental para as casas de apostas e os apostadores.

Qual foi o desempenho do modelo de previsão de IA na previsão dos resultados das partidas? Beal et al. [3] avaliaram a precisão de diferentes métodos de aprendizado de máquina aplicados em diversos esportes. As redes neurais tiveram o melhor desempenho na NCAA, com uma precisão de 72,2%, em comparação com sua precisão de previsão de 68,8% e 67,5% na Liga dos Campeões de Futebol e na Liga de Rúgbi. As árvores de decisão alcançaram uma precisão de 69,16% no basquete, 41,72% no futebol e 58% no futebol americano. As Máquinas de Vetores de Suporte (SVM) alcançaram uma precisão de 75% para o críquete e 54,5% para o futebol americano, utilizando o kernel RBF. Os métodos de agrupamento, floresta aleatória e reforço de gradiente também alcançaram mais de 50% de precisão para o futebol americano e o beisebol. Beal também destacou que, embora a IA tenha demonstrado potencial para prever resultados, ainda não conseguiu prever com precisão significativamente superior à das casas de apostas.

No passado, as equipes técnicas prescreviam treinos para preparar a equipe ou ajudar os atletas a atingir o desempenho ideal e reduzir o risco de lesões, baseando-se principalmente em décadas de experiência pessoal [4], o que poderia ser visto como um processo em que enormes quantidades de dados invisíveis eram processadas pelo cérebro humano. Atualmente, a IA (Inteligência Artificial) utiliza abordagens estatísticas contemporâneas para construir modelos de melhoria de desempenho, garantindo o desenvolvimento eficaz de programas de treinamento ideais [5]. Seidenschwarz et al [6] projetaram um Sistema de Análise de Dados (DAS) integrando análises qualitativas e quantitativas, bem como visualizações que uniam dados brutos, dados de eventos e dados de vídeo para apoiar a tomada de decisões

em esportes de competição. Sob a arquitetura do DAS, ele pode ser adaptado rapidamente a diferentes esportes.

Além da previsão de resultados de partidas e da elaboração de estratégias, a tecnologia de IA tem sido amplamente aplicada na avaliação de lesões. Redes neurais, classificadores de árvores de decisão e máquinas de vetores de suporte têm sido utilizados no futebol, basquete, futebol americano, futebol australiano e handebol [7].

Estudos iniciais sobre a previsão de resultados de lutas de artes marciais mistas utilizando regressão logística [8]. Posteriormente, uma série de algoritmos de aprendizado de máquina, incluindo Perceptron, Random Forests, classificador de Árvores de Decisão, classificador de Descida de Gradiente Estocástico (SGD), Máquina de Vetores de Suporte (SVM) e classificadores K-Vizinhos Mais Próximos (KNN), foram utilizados para testar a eficácia na previsão de lutas do UFC com base em um conjunto de séries temporais de dados de um lutador antes de cada luta [9].

Um estudo de caso sobre o Campeonato Mundial de Boxe constatou que a seleção de características foi considerada o fator mais influente no desempenho da previsão [10]. As características incluem métricas de desempenho individuais, como golpes lançados e acertados, knockdowns e manobras defensivas, dados históricos de lutas, atributos físicos, incluindo idade, peso, altura etc., análise do adversário e

, duração e intensidade.

Sharma e A. K. Uttam alcançaram um aumento de mais de 10% na precisão em relação a estudos anteriores, aplicando um modelo de aprendizado profundo baseado em redes neurais multicamadas.

Como existem mais de seis modelos de aprendizado de máquina que têm sido aplicados na previsão de resultados de partidas em diversos esportes, quais modelos teriam melhor desempenho na previsão e na elaboração de estratégias no UFC? Este estudo comparará três tipos de modelos de aprendizado de máquina para avaliar sua capacidade em termos de precisão de previsão e orientação na elaboração de estratégias.

3 Metodologia

3.1 Coleta de dados

O conjunto de dados utilizado neste estudo provém da comunidade Kaggle e foi disponibilizado gratuitamente pelo membro RAJEEV WARRIER [12]. O conjunto de dados é composto por informações extraídas do site ufcstats, abrangendo todas as lutas do UFC realizadas entre 11 de março de 1994 e 20 de março de 2021, totalizando 6.012 combates.

Os dados contêm informações sobre ambos os lutadores, detalhes da luta, resultados das disputas e métricas de desempenho. Os lutadores são representados pelas cores "vermelho" e "azul" (correspondentes aos cantos vermelho e azul), e suas informações incluem características físicas de cada um, como peso, altura, alcance, postura e idade na época da luta. As informações das lutas são listadas com detalhes sobre a data, local, árbitro e se foi uma luta pelo título. O resultado da luta apresenta o vencedor, vitórias por diferentes métodos e o total de vitórias, derrotas e empates de cada lutador. As métricas de desempenho incluem métricas de golpes, métricas de grappling, métricas de finalização e reversão, zonas de golpe e métricas de controle.

3.2 Pré-processamento de dados

O conjunto de dados é carregado no ambiente de análise utilizando a linguagem R após ser baixado do Kaggle. Os registros com valores ausentes (NA) são removidos para garantir que os modelos sejam treinados com dados completos. As características, tais como atributos físicos e métricas de desempenho, são normalizadas para garantir uma escala comparável. Uma vez que o

Tabela 1: Categorias de variáveis

Características físicas do lutador	Detalhes da luta	Métricas de desempenho do lutador (absolutas)	Índice de sucesso de desempenho do lutador	Diferença do lutador em relação ao adversário	Histórico de lutas do lutador
lutador	Árbitro	média_KD	SIG_STR_pct	diferença_SIG_STR_pc	total_lutas
Altura_cm	data	média_SIG_STR_pct	TD_pct	diferença_de_TD_pct	tempo_total_de_luta segundos
alcance_cms	localização	avg_TD_pct	SUB_ATT_pct	diferença_de_porcentag	total_de_rondas_disputadas
				em_de_tentativas_de_fi	
				nalização	
Peso_kg	título_luta	média_tentativas_de_finaliza	REV_pct	diferença_de_REV_pct	total_lutas_pelo_título
		ção			
idade	categoria de peso	média_REV	porcentagem	dif_pct_cabeça	sequência_de_vitórias_a
		média_SIG_STR_att	_cabeça	dif_pct_corpo	tual
		média_TOTAL_STR_att	porcentagem_	dif_pct_perna	sequência_de_derrotas_at
		média_TD_att	corpo	DIS-	ual
			porcentagem		sequência_de_vitórias_m
			_perna		ais_longa
			DISTANCE_pct		
		média_HEAD_att	CLINCH_pct	diferença_pct_TANCE	
		média_ataques_corpo	GROUND_pct	diferença_de_porcentagem_de_clinch	
		média_ataques_perna		dif_porcentagem_no_ch	
		média_ataques_distância		ão dif_KD	
		média_ataques_clinch		dif_tempo_CTRL	
				diferença no tempo total de	
				luta vs. diferença no total de	
				rounds lutados	
		média_ataques_no_chão			

O estudo envolve análise de séries temporais, características de defasagem, médias móveis e estatísticas cumulativas são criadas a partir das existentes para tendências de desempenho histórico para melhorar a precisão da previsão e insights estratégicos para lutas do UFC.

3.3 Variáveis

Todas as variáveis são classificadas em 5 tipos, resumidos na Tabela 1.

3.4 Métodos de Aprendizado de Máquina

Três métodos de aprendizado de máquina serão adotados neste estudo,

floresta aleatória, Árvores de Decisão com Reforço de Gradiente (GBDT), Máquinas de Vetores de Suporte (SVM).

Random Forest e GBDT são métodos de aprendizado por conjunto. A Random Forest reduz o risco de sobreajuste, tornando-a adequada para

conjuntos de dados complexos e fornece um indicador claro da importância das características, calculando a média de várias árvores de decisão. O GBDT frequentemente alcança maior precisão preditiva do que muitos outros algoritmos, reduzindo o viés e a variância. Ao mesmo tempo, fornece métricas de importância das características semelhantes às da Random Forest. O SVM é um modelo de aprendizado supervisionado que é especialmente útil para conjuntos de dados com um grande número de características em comparação com o número de amostras. A Random Forest pode ajudar a estabelecer a previsão inicial e revelar as características importantes. O GBDT pode melhorar a precisão. Nosso estudo inclui mais de 100 características no conjunto de dados, com as quais o SVM pode trabalhar bem. Portanto, este estudo comparará o desempenho de ambos em termos de precisão de previsão e as 10 características mais importantes que eles identificam, respectivamente.

3.4.1 Floresta Aleatória. A Floresta Aleatória constrói múltiplas árvores de decisão, cada uma delas treinada com um subconjunto de dados selecionado aleatoriamente. Em cada nó, apenas um subconjunto aleatório de características é considerado

para divisão. A previsão final é a moda ou a média de todas as previsões da árvore.

$$\hat{y} = \frac{1}{n} \sum_{i=1}^n h_i(x)$$

(1)

O n: número de árvores.

O hi(x): resultado da previsão de cada árvore.

3.4.2 Árvores de Decisão com Reforço de Gradiente (GBDT). O GBDT treina sequencialmente várias árvores de decisão, com cada árvore tentando corrigir os erros de previsão de todas as árvores anteriores. Ele utiliza o algoritmo de descida de gradiente para minimizar uma função de perda, a fim de melhorar a precisão da previsão do modelo

$$\hat{y} = \sum_{m=1}^M W_m f_m(x)$$

(2)

O Wm: peso de W.

3.4.3 Máquinas de Vetores de Suporte (SVM). A SVM é um modelo de classificação que encontra um hiperplano ótimo para separar amostras de diferentes classes.

$$w \cdot x + b = 0, \min w, b - \frac{1}{2} \|w\|^2 + C \sum_i \xi_i$$

(3)

O w: o vetor normal. O b: o termo de desvio.

As (xi: variáveis de folga.

O parâmetro de regularização C:.

Para cada método de aprendizado de máquina, aplicamos todas as características do conjunto de dados ao modelo, a fim de examinar a precisão e a validação, identificando as 10 características que mais contribuem para a previsão, as quais são consideradas características estratégicas. Uma vez identificadas as 10 características que mais contribuem, novos modelos com essas características selecionadas seriam construídos para cada método de aprendizado de máquina. Assim, poderíamos verificar se há uma mudança significativa com menos características, mas mais importantes.

Tabela 2: Comparação do desempenho de 3 métodos de aprendizado de máquina

Modelo	Precisão	Kappa	Sensibilidade	Especificidade
Floresta Aleatória	0,6566	0,1910	0,3134	0,8601
GBDT	0,6540	0,1988	0,3486	0,8351
SVM	0,6501	0,1549	0,2500	0,8873

Tabela 3: Comparação das 10 principais características de 3 modelos de aprendizado de máquina

Posição	Random Forest	GBDT	SVM
1	Data	Data	Data
2	Diferença de idade	Diferença de idade	Diferença de idade
3	Porcentagem de clinch	Tentativas de golpes no corpo	Diferença no total de lutas
4	Tempo total de luta	Tentativas de golpes nas pernas	Idade do lutador
5	Porcentagem no chão	Diferença de tempo de controle	Tentativas de golpes no corpo
6	Porcentagem de clinch	Porcentagem de clinch	Diferença de alcance
7	Porcentagem de quedas	Porcentagem de lutas no chão	Total de lutas pelo título
8	Porcentagem de reversões	Total de rounds disputados	Diferença de derrotas
9	Diferença de alcance	Porcentagem de reversão	Golpes significativos tentados
10	Tentativas de finalização	Total de golpes acertados pelo adversário	Golpes na cabeça acertados

3.5 Resultados

A Tabela 2 apresenta o desempenho dos modelos Random Forest, GBDT e SVM em termos de precisão, Kappa, sensibilidade e especificidade, considerando todas as características. A precisão avalia a capacidade de previsão do modelo. Quanto maior a precisão, melhor o desempenho do modelo. O Kappa mede a concordância entre a classificação prevista e a real. O Kappa varia de -1 a 1. Quando o Kappa está mais próximo de 1, isso indica uma melhor concordância; se for negativo, sugere que a concordância é pior do que o acaso. A sensibilidade mede a proporção de casos positivos reais que são corretamente identificados pelo modelo. Uma sensibilidade mais alta indica maior eficácia na identificação de casos positivos. A especificidade mede a proporção de casos negativos reais que são corretamente identificados pelo modelo.

Todos os três modelos apresentam precisão semelhante, em torno de 65%, superior a 50%, o que sugere que sua capacidade de previsão é semelhante. O índice Kappa dos três modelos é inferior a 0,6, o que geralmente indica uma concordância substancial. Portanto, os três modelos não apresentam bom desempenho em termos de consistência da classificação. O GBDT é melhor do que os outros dois modelos em Kappa e sensibilidade, indicando que o GBDT está funcionando bem na detecção de amostras positivas. O SVM apresenta o pior desempenho entre os três métodos em Kappa e sensibilidade, indicando que seu desempenho é ruim em termos de sensibilidade. No entanto, o SVM apresenta o melhor desempenho em especificidade, sugerindo que é o melhor na identificação correta de amostras negativas. Em conclusão, não há diferença significativa entre os três métodos de aprendizado de máquina na previsão do resultado da partida. Se o usuário, ou as partes interessadas na partida, considerarem importante maximizar a detecção de casos positivos, o GBDT é a melhor escolha. No entanto, se o objetivo for minimizar os falsos positivos, o SVM é a melhor escolha. E o Random Forest oferece uma abordagem mais equilibrada na previsão.

A Tabela 3 apresenta as 10 características que mais contribuem para a previsão em cada um dos três modelos. Podemos observar que a data é a que mais

característica importante na previsão. Isso pode estar relacionado à organização do plano de treinamento do lutador, ou seja, se o treinamento termina tarde demais para que ele participe da luta, que ocorreu na data em questão. A segunda característica mais importante é a diferença de idade entre os dois lutadores. A idade está diretamente relacionada ao estado físico do lutador, bem como à sua experiência. Uma diferença de idade maior significa mais experiência, mas também pode ser necessário um tempo mais longo para se recuperar. Além dos maiores contribuintes mútuos, que são a Data e a Diferença de Idade, três métodos de aprendizado de máquina têm sua própria seleção. Essas características mais importantes abrangem as características físicas do lutador, detalhes da luta, métricas de desempenho do lutador (valores absolutos) que contabilizam os ataques do lutador etc., sua taxa de sucesso e também as métricas de desempenho do adversário. É notável que mais 5 das características importantes dizem respeito aos detalhes da luta, incluindo a duração total da luta, o número de lutas pelo título em que o lutador participou, o número de rounds disputados pelo lutador, a diferença no número total de lutas entre os dois lutadores e a diferença no número total de lutas entre os dois lutadores. A taxa de sucesso dos golpes ou movimentos tentados pelo lutador durante um clinch, o controle no solo, as quedas bem-sucedidas e as reversões também são importantes para fazer a previsão. Os valores absolutos de golpes no corpo tentados, golpes nas pernas tentados, golpes significativos tentados e golpes na cabeça acertados também são índices importantes para melhorar a precisão da previsão. Do ponto de vista do adversário, a diferença no tempo em que cada lutador controlou a luta e o número total de golpes acertados pelo adversário são as características selecionadas.

Realiza-se uma análise mais aprofundada e uma comparação através da construção de modelos com apenas 10 características aplicadas em três modelos de aprendizado de máquina, a fim de verificar se há mudanças significativas. A Tabela 4 apresenta a comparação entre precisão, Kappa, sensibilidade e especificidade dos modelos Random Forest, GBDT e SVM.

O GBDT apresenta o melhor desempenho na previsão, com precisão de 66,71%, superior aos 66,58% do Random Forest e aos 64,48% do SVM. Ambos

Tabela 4: Comparação do desempenho de 3 modelos de aprendizado de máquina com 10 características

Modelo	Precisão	Kappa	Sensibilidade	Especificidade
Floresta Aleatória	0,6658	0,2267	0,3662	0,8434
GBDT	0,6671	0,2339	0,3803	0,8372
SVM	0,6448	0,1310	0,2148	0,8998

O Random Forest e o GBDT alcançaram uma melhoria na precisão de previsão, enquanto o SVM apresenta uma queda na precisão de previsão, sendo que os três modelos estão limitados a 10 características. O SVM apresenta o pior desempenho em Kappa e sensibilidade em comparação com os outros dois modelos; no entanto, alcança o melhor desempenho em especificidade, com 89,98%, em comparação com 84,34% do Random Forest e 83,72% do GBDT. O resultado do desempenho do SVM está alinhado com seu desempenho com todas as características. O GBDT continua a apresentar um desempenho melhor em Kappa e sensibilidade, que são superiores aos modelos com todas as características: 0,2339 em Kappa e 0,3803 em sensibilidade, indicando que o novo modelo com menos características poderia utilizar a característica mais importante para melhorar a confiabilidade, além da precisão. Enquanto isso, o Random Forest também mostra uma ligeira melhora na precisão e na confiabilidade, passando de 65,66% no modelo com todas as características para 66,58% com 10 características na precisão, e obteve uma melhora de 0,1910 com todas as características para 0,2267 com 10 características no Kappa, sugerindo que um conjunto mais focado de características poderia ajudar o modelo a fornecer uma previsão melhor.

4 CONCLUSÃO

Este estudo avaliou o desempenho do Random Forest, das Árvores de Decisão com Reforço de Gradiente (GBDT) e das Máquinas de Vetores de Suporte (SVM) na previsão do resultado das partidas com o conjunto de dados de características completas e características selecionadas. As características selecionadas para cada modelo foram identificadas com base nos 10 principais contribuintes na previsão do resultado. A precisão geral com todas as características dos três métodos de aprendizado de máquina está acima de 60%. O foco em características limitadas com maior contribuição não trouxe melhorias significativas na previsão, indicando que há mais espaço para aprimorar os modelos ou testar mais combinações de características diferentes.

É digno de nota que a data e a diferença de idade são as duas características mais importantes que influenciam a precisão da previsão nos três modelos. Essas descobertas fornecem insights para a elaboração de estratégias para os lutadores na elaboração de seus planos de treinamento, a fim de aproveitar seus pontos fortes e reduzir as possíveis perdas causadas por seus pontos fracos. A diferença de idade está relacionada à experiência, resistência e tempo de recuperação, fatores que influenciam o resultado da luta. Por outro lado, a idade absoluta também é uma característica importante no SVM, que influencia o tempo de reação do lutador, a experiência,

e também no desempenho físico. A identificação das características mais importantes, mesmo que variem entre os diferentes métodos de aprendizado de máquina, fornece uma visão abrangente e valiosa para a elaboração de estratégias antes da partida e o ajuste das decisões táticas durante a partida.

O desempenho do nosso estudo depende fortemente da qualidade e da integridade dos dados. Removemos todos os registros contendo valores ausentes, que eram principalmente da década de 1990, pois os dados incompletos poderiam afetar a confiabilidade das previsões. Os modelos são treinados com dados históricos e testados também com dados históricos; portanto, sua verdadeira capacidade de previsão é incerta quando aplicados a dados futuros.

Referências

[1] <https://www.plunkettresearch.com/statistics/Industry-Statistics-Sports-Industry->
Visão geral das estatísticas e do tamanho do mercado/
[2] Lapham AC, Bartlett RM. O uso da inteligência artificial na análise do desempenho esportivo: uma revisão das aplicações na análise da marcha humana e futuras direções de pesquisa para a biomecânica esportiva. J Sports Sci. 1995;13(3):229-37.
[3] Beal, R., Norman, T. J., & Ramchurn, S. D. (2019). Inteligência artificial para esportes coletivos: uma pesquisa. The Knowledge Engineering Review, 34, e28.
[4] Nassiss GP. Liderança na ciência e na medicina: você consegue ver a lacuna? Sci Med Football. 2017;1(3):195-6.
[5] Borresen J, Lambert MI. A quantificação da carga de treinamento, a resposta a o treinamento e o efeito no desempenho. Sports Med. 2009;39(9):779-95.
[6] Seidenschwarz, P.G. (2021). Análise baseada em dados para a tomada de decisões em esportes de jog - o (Tese de doutorado, Universidade de Brasília)
[7] Claudino, J.G., Capanema, D. D. O., de Souza, T. V., Serrão, J. C., Machado Pereira, A. C., & Nassiss, G. P. (2019). Abordagens atuais para o uso da inteligência artificial na avaliação do risco de lesões e na previsão de desempenho em esportes coletivos: uma revisão sistemática e meta-. Sports medicine-open, 5, 1-12.
[8] Johnson, J. D. (2012). Previsão dos resultados de lutas de artes marciais mistas com novas variáveis de luta baseadas em algoritmos de busca de harmonia () (Tese de doutorado, Universidade da Geórgia).
[9] Hitkul, Aggarwal, K., Yadav, N., & Dwivedy, M. (2019). Um estudo comparativo de algoritmos de aprendizado de máquina para previsão prévia de lutas do UFC. Em Harmony Search and Nature Inspired Optimization Algorithms: Theory and Applications, ICHSA 2018 (pp. 67-76). Springer Singapore.
[10] Thisani, S.K. (2024). Desenvolvimento de uma rede neural artificial de alto desempenho para previsão de resultados esportivos: estudo de caso sobre o Campeonato Mundial de Boxe. Revista Internacional de Ciência da Computação no Esporte, 2024, Volume 23, Número 2, Página 1.
[11] G. Sharma e A. K. Uttam, "Modelo de rede neural multicamadas para previsão de vencedores em artes marciais mistas", 5ª Conferência Internacional sobre Sistemas de Informação es e Redes de Computadores (ISCON), Mathura, Índia, 2021, pp. 1-5
[12] <https://www.kaggle.com/datasets/rajeevww/ufcdata/data>